Sisteme Distribuite - Laborator 13

Apache Kafka şi Apache Spark

Introducere

Apache Kafka

Apache Kafka este o platformă de fluxuri de evenimente distribuite, capabilă să gestioneze miliarde de evenimente pe zi. Această platformă poate:

- să publice/să se aboneze la fluxuri de înregistrări (records), în mod similar cu o coadă de mesaje;
- să stocheze fluxuri de înregistrări într-un mod durabil şi tolerant la erori (fault-tolerant);
- să proceseze fluxuri de înregistrări pe măsură ce apar.

Pentru mai multe detalii, vezi:

- Cursurile de la disciplina *Sisteme distribuite*
- Laboratorul 10 de la disciplina *Sisteme distribuite*
- https://www.confluent.io/what-is-apache-kafka/
- https://kafka.apache.org/intro
- https://kafka.apache.org/documentation/

Apache Spark

Spark este un motor de uz general de procesare distribuită a datelor. Peste framework-ul Spark, există biblioteci pentru SQL, învăţare automată (machine learning), calcule pe grafuri (graph computation), procesări de fluxuri, care pot fi folosite împreună într-o aplicaţie.

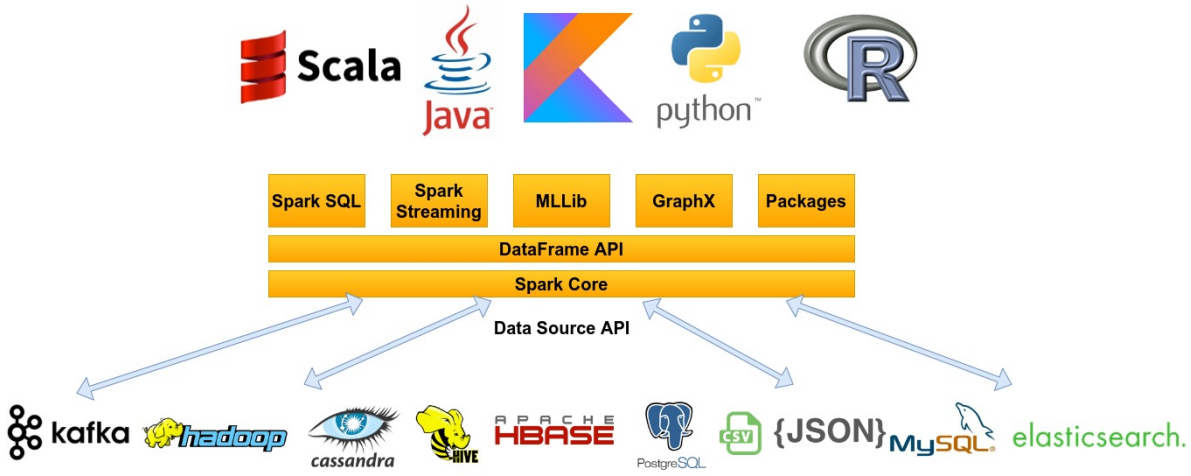

Cazuri tipice de utilizare:

- **Procesarea fluxurilor (stream processing)**: deşi este fezabilă stocarea datelor pe disk şi procesarea lor ulterioară, uneori este necesar să se acţioneze asupra datelor pe măsură ce acestea sosesc (spre exemplu tranzacţiile financiare trebuie procesate în timp real pentru a identifica şi refuza tranzacţii potenţial frauduloase)
- **Învăţare automată (machine learning)**: Soluţiile software pot fi antrenate să identifice şi să acţioneze în funcţie de trigger-ele din seturile de date bine înţelese, înainte de a aplica aceleaşi soluţii la date noi şi la date necunoscute. Abilitatea framework-ului Spark de a stoca date în memorie şi de a executa rapid interogări repetate îl face o alegere potrivită pentru antrenarea algoritmilor de învăţare automată.
- **Analiză interactivă (interactive analytics)**: procesul de interogare interactivă necesită un sistem precum Spark care să fie capabil să răspundă şi să se adapteze rapid.

- **Integrarea datelor (data integration)**: *Spark* şi *Hadoop* sunt folosite din ce în ce mai mult pentru a reduce costul şi timpul necesar pentru procesul **ETL** (Extract, Transform, Load)

Avantaje:

- Simplitate
- Viteză
- Suport
- Pipeline-uri de date

Pentru mai multe detalii despre framework-ul Spark, precum şi istoria acestuia (de ce s-a trecut de la Hadoop la Spark), vezi:

- Cursurile de la disciplina *Sisteme distribuite*
- https://mapr.com/blog/spark-101-what-it-what-it-does-and-why-it-matters/
- https://spark.apache.org/docs/2.4.5/

Spark RDD (Resilient Distributed Dataset)

Abstractizarea principală oferită de Spark este un ***RDD***, mai precis, o colecţie de elemente partiţionate pe nodurile dintr-un cluster pe care se poate acţiona în paralel.

O altă abstractizare în Spark reprezintă ***variabilele partajate*** care pot fi utilizate în operaţii paralele. În mod implicit, când Spark execută o funcţie în paralel ca un set de task-uri pe diferite noduri, furnizează o copie a fiecărei variabile utilizate în funcţie către fiecare task. Uneori, este nevoie totuşi de partajarea unei variabile între task-uri. Framework-ul Spark suportă două tipuri de variabile partajate: *variabile de broadcast* care pot fi utilizate pentru cache-uirea unei variabile în memorie pe toate nodurile, şi *acumulatori* care sunt variabile în care doar se adaugă (counter, sume).

Pentru mai multe detalii, vezi:

- https://spark.apache.org/docs/2.4.5/rdd-programming-guide.html

Crearea unui proiect Spark (RDD)

Se creează un nou proiect Maven, se bifează opţiunea „Create from archetype” şi se selectează: *org.jetbrains.kotlin:kotlin-archetype-jvm -> kotlin-archetype-jvm:1.3.72*. Se adaugă apoi următoarea dependenţă în *pom.xml*:

```
<dependency>
    <groupId>org.apache.spark</groupId>
    <artifactId>spark-core_2.12</artifactId>
    <version>2.4.5</version>
</dependency>
```

Este nevoie de crearea unui obiect *JavaSparkContext* care îi spune framework-ului Spark cum să acceseze un cluster.

Observaţie: Pentru simplitate, se va configura Spark să fie executat local. Pentru o imagine de ansamblu asupra configurării Spark, vezi:

- https://spark.apache.org/docs/2.4.5/submitting-applications.html

Spark SQL

Spark SQL este un modul al framework-ului Spark pentru procesarea datelor structurate. O utilizare a Spark SQL este pentru a executa interogări SQL. Rezultatele returnate în urma unei interogări vor fi *Dataset-uri* sau *DataFrame-uri*.

Dataset-ul este o colecţie distribuită de date, ce are atât avantajele unui RDD (funcţii lambda) cât şi pe cele ale motorului de execuţie optimizat al Spark SQL.

Un DataFrame este un Dataset organizat în coloane cu denumiri. Conceptual, este echivalent cu o tabelă dintr-o bază de date relaţională, dar cu mai multe optimizări.

Pentru mai multe detalii, vezi:

- https://spark.apache.org/docs/2.4.5/sql-getting-started.html

De asemenea, vezi funcţiile de agregare pentru DataFrame-uri:

- https://spark.apache.org/docs/2.4.5/api/scala/index.html#org.apache.spark.sql.functions$

Adăugarea componentei Spark SQL

Pentru a include componenta Spark SQL în proiect, este necesară adăugarea următoarei dependenţe în fişierul *pom.xml:*

```
<dependency>
    <groupId>org.apache.spark</groupId>
    <artifactId>spark-sql_2.12</artifactId>
    <version>2.4.5</version>
</dependency>
```

Securitate

Securitatea este dezactivată în mod implicit în Spark. Acest lucru înseamna că, în mod implicit, aplicaţia este vulnerabilă la atacuri.

Framework-ul Spark poate fi securizat prin următoarele aspecte:

- Spark RPC (protocolul de comunicare între procese Spark)
- Criptarea spaţiului de stocare local (local storage encryption)
- Web UI
- Configurarea porturilor pentru securitatea reţelei
- Kerberos
- Jurnal de evenimente (event logging)

```
val sparkConf = SparkConf().setMaster("local[4]")
                           .setAppName("Spark Example")
                           .set("spark.io.encryption.enabled", "true")
                           .set("spark.io.encryption.keySizeBits","256")
val sparkContext = JavaSparkContext(sparkConf)
```

Pentru mai multe detalii privind opţiunile de securizare ale unei aplicaţii Spark, precum şi modul în care pot fi adăugate aceste configurări, vezi:

- https://spark.apache.org/docs/latest/configuration.html
- https://spark.apache.org/docs/latest/security.html

Pentru securizarea Apache Kafka, vezi documentaţia oficială, capitolul 7:

- https://kafka.apache.org/documentation/#security

Spark Streaming

Spark Streaming primeşte fluxuri de date în timp real, le împarte în loturi (batches) care sunt procesate apoi de motorul Spark (Spark Engine) pentru a genera fluxul final de rezultate sub formă de loturi (batches).

Modul de funcţionare al Spark Streaming

Spark Streaming oferă o abstractizare de nivel înalt numită *flux discret* (discretized stream) sau *DStream,* ce reprezintă un flux continuu de date. DStream-urile pot fi create fie din fluxuri de date de intrare din surse precum *Kafka, Flume* şi *Kinesis*, fie aplicând operaţiuni de nivel înalt pe alte DStream-uri. Un DStream este reprezentat intern ca o secvenţă de RDD (abstractizarea Spark-ului pentru un set de date imutabil distribuit).

ATENȚIE: Un program Spark Streaming executat local trebuie să utilizeze în URL-ul master "local[n]", unde n ≥ 2, deoarece un thread va executa receiver-ul, iar restul vor procesa datele primite.

Există mai multe surse de date pentru Spark Streaming:

- **TCP:**

```
val lines: JavaReceiverInputDStream<String> =
streamingContext.socketTextStream("localhost", 9999)
```

- **fişiere text:**

```
streamingContext.textFileStream(dataDirectory)
```

- **flux de fişiere**

```
streamingContext.fileStream<KeyClass, ValueClass,
InputFormatClass>(dataDirectory)
```

- surse avansate: Kafka, Flume, Kinesis

Pentru mai multe detalii, vezi:

- https://spark.apache.org/docs/2.4.5/streaming-programming-guide.html **(în special transformările pe DStream-uri şi operaţiile de output pe DStream-uri)**
- https://spark.apache.org/docs/2.4.5/streaming-custom-receivers.html

Adăugarea componentei Spark Streaming

Pentru a include componenta Spark Streaming în proiect, este necesară adăugarea următoarei dependenţe în fişierul *pom.xml:*

```
<dependency>
    <groupId>org.apache.spark</groupId>
    <artifactId>spark-streaming_2.12</artifactId>
    <version>2.4.5</version>
</dependency>
```

Integrarea Spark Streaming cu Kafka

Se va adăuga următoarea dependenţă în fişierul *pom.xml:*

```
<dependency>
    <groupId>org.apache.spark</groupId>
    <artifactId>spark-streaming-kafka-0-10_2.12</artifactId>
    <version>2.4.5</version>
</dependency>
```

Pentru mai multe detalii, vezi:

- https://spark.apache.org/docs/2.4.5/streaming-kafka-0-10-integration.html

Exemple

Exemplul 1: Spark RDD

Vezi comentariile cu explicaţii din cod.

```
package com.sd.laborator

import org.apache.spark.SparkConf
import org.apache.spark.api.java.JavaSparkContext
import org.apache.spark.api.java.function.Function
import org.apache.spark.api.java.function.Function2
import org.apache.spark.broadcast.Broadcast
import org.apache.spark.storage.StorageLevel


internal class GetLength : Function<String?, Int?> {
    override fun call(p0: String?): Int? {
        return p0?.length ?: 0
    }
}

internal class Sum : Function2<Int?, Int?, Int?> {
    override fun call(p0: Int?, p1: Int?): Int? {
        return (p0?.toInt() ?: 0) + (p1?.toInt() ?: 0)
    }
}


fun main(args: Array<String>) {
    // configurarea Spark
    val sparkConf = SparkConf().setMaster("local").setAppName("Spark
Example")
    // initializarea contextului Spark
    val sparkContext = JavaSparkContext(sparkConf)

    val items = listOf("123/643/7563/2134/ALPHA",
"2343/6356/BETA/2342/12", "23423/656/343")
    // paralelizarea colectiilor
    val distributedDataset = sparkContext.parallelize(items)

    // 1) spargerea fiecarui string din lista intr-o lista de
substring-uri si reunirea intr-o singura lista
    // 2) filtrarea cu regex pentru a pastra doar numerele
    // 3) conversia string-urilor filtrate la int prin functia de
mapare
    // 4) sumarea tuturor numerelor prin functia de reducere
    val sumOfNumbers = distributedDataset.flatMap {
it.split("/").iterator() }
        .filter { it.matches(Regex("[0-9]+")) }
        .map { it.toInt() }
        .reduce {total, next -> total + next }
    println(sumOfNumbers)
```

```
    // seturi de date externe
    // setul de date nu este inca incarcat in memorie (si nu se
actioneaza inca asupra lui)
    val lines = sparkContext.textFile("src/main/resources/data.txt")

    // pentru utilizarea unui RDD de mai multe ori, trebuie apelata
metoda persist:
    lines.persist(StorageLevel.MEMORY_ONLY())

    // functia de mapare reprezinta o transformare a setului de date
initial (nu este calculat imediat)
    // abia cand se ajunge la functia de reducere (care este o
actiune) Spark imparte operatiile in task-uri
    // pentru a fi rulate pe masini separate (fiecare masina executand
o parte din map si reduce)
    // exemplu cu functii lambda:
    val totalLength0 = lines.map { s->s.length }.reduce { a: Int, b:
Int -> a + b }

    // trimiterea unor functii catre Spark
    val totalLength1= lines.map(object : Function<String?, Int?> {
            override fun call(p0: String?): Int? {
                return p0?.length ?: 0
            }
        }).reduce(object : Function2<Int?, Int?, Int?> {
            override fun call(p0: Int?, p1: Int?): Int? {
                return (p0?.toInt() ?: 0) + (p1?.toInt() ?: 0)
            }
        })

    // sau daca scrierea functiilor inline sau a celor lambda este
greoaie, se pot utiliza clase
    val totalLength2 = lines.map(GetLength()).reduce(Sum())
    println(totalLength0)
    println(totalLength1)
    println(totalLength2)

    // variabila partajata de tip broadcast
    // trimiterea unui set de date ca input catre fiecare nod intr-o
maniera eficienta:
    val broadcastVar: Broadcast<List<Int>> =
sparkContext.broadcast(listOf(1, 2, 3))
    val totalLength3 = lines.map { s->s.length +
broadcastVar.value()[0] }.reduce { a: Int, b: Int -> a + b }
    println(totalLength3)

    //variabila partajata de tip acumulator
    val accumulator = sparkContext.sc().longAccumulator()
    sparkContext.parallelize(listOf(1, 2, 3, 4)).foreach { x ->
accumulator.add(x.toLong()) }
    println(accumulator)
```

```
    // oprirea contextului Spark
    sparkContext.stop()
}
```

Se va crea fişierul *src/main/resources/data.txt* cu câteva linii de text oarecare.

Exemplul 2.1: Spark SQL - conectare la bază de date MySQL

Pentru conectarea la o bază de date MySQL este necesară adăugarea următoarei dependenţe în fişierul *pom.xml*:

```
<dependency>
    <groupId>mysql</groupId>
    <artifactId>mysql-connector-java</artifactId>
    <version>8.0.19</version>
</dependency>
```

Pentru crearea unei baze de date şi a unei tabele Person, precum şi pentru popularea acesteia, se va executa următorul script în consola MySQL:

```
CREATE DATABASE IF NOT EXISTS sd_database;
USE sd_database;
CREATE TABLE IF NOT EXISTS Person (ID int PRIMARY KEY, LastName
varchar(255), FirstName varchar(255), Age int);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(1, "Popescu",
"Ion", 20);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(2, "Ionescu",
"Mariana", 20);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(3, "Codreanu",
"Cristian", 20);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(4, "Cantemir",
"Roxana", 21);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(5, "Anghel",
"Vlad", 21);
INSERT INTO Person(ID, LastName, FirstName, Age) VALUES(6, "Bujor",
"Florina", 22);
COMMIT;
```

Observaţie: se poate pune scriptul într-un fişier mysql_init.sql, apoi dintr-un terminal deschis în directorul scriptului se porneşte consola MySQL şi se execută comanda:

```
source mysql_init.sql
```

Codul sursă

Vezi comentariile cu explicaţii din cod.

```
package com.sd.laborator

import org.apache.spark.sql.SparkSession

fun main(args: Array<String>) {
    val spark = SparkSession.builder()
        .appName("Java Spark SQL example")
```

```
        .config("spark.master", "local[4]")
        .orCreate
    // Crearea unui DataFrame pe baza unei tabele "Person" stocata
intr-o baza de date MySQL
    //val url =
"jdbc:mysql://yourIP:yourPort/databaseName?user=yourUsername&password=
yourPassword&serverTimezone=UTC"
    val url =
"jdbc:mysql://localhost:3306/sd_database?user=admin&password=pass&ser-
verTimezone=UTC"
    val df = spark.sqlContext()
                .read()
                .format("jdbc")
                .option("url", url)
                .option("dbtable", "Person")
                .load()

    // Afisarea schemei DataFrame-ului
    df.printSchema()

    // Numararea persoanelor dupa varsta
    val countsByAge = df.groupBy("age").count()
    countsByAge.show()

    // Salvarea countsByAge in src/main/resources/sql_output in format
JSON

countsByAge.write().format("json").save("src/main/resources/sql_out-
put")
}
```

Exemplul 2.2: Spark SQL

```
package com.sd.laborator

import org.apache.spark.api.java.JavaRDD
import org.apache.spark.api.java.function.MapFunction
import org.apache.spark.sql.*
import org.apache.spark.sql.functions.col
import java.io.Serializable


// clasa bean
class Person: Serializable {
    var name: String? = null
    var age = 0
}


fun main(args: Array<String>) {
    // configurarea si crearea sesiunii Spark SQL
    val sparkSession = SparkSession.builder()
        .appName("Java Spark SQL example")
```

```
        .config("spark.master", "local")
        .orCreate

    // initializarea unui DataFrame prin citirea unui json
    val df: Dataset<Row> =
sparkSession.sqlContext().read().json("src/main/resources/people.json"
)

    // afisarea continutului din DataFrame la consola
    df.show()

    // Afisarea schemei DataFrame-ului intr-o forma arborescenta
    df.printSchema();

    // Selectarea coloanei nume si afisarea acesteia
    df.select("name").show();

    // Selectarea tuturor datelor si incrementarea varstei cu 1
    df.select(col("name"), col("age").plus(1)).show();

    // Selectarea persoanelor cu varsta > 21 ani
    df.filter(col("age").gt(21)).show();

    // Numararea persoanelor dupa varsta
    df.groupBy("age").count().show();

    // Inregistarea unui DataFrame ca un SQL View temporar
    df.createOrReplaceTempView("people")

    // Utilizarea unei interogari SQL pentru a selecta datele
    val sqlDF: Dataset<Row> = sparkSession.sql("SELECT * FROM people")
    sqlDF.show()

    // Inregistrarea unui DataFrame ca un SQL View global temporar
    df.createGlobalTempView("people");

    // Un SQL View global temporar este legat de o baza de date a
sistemului: `global_temp`
    sparkSession.sql("SELECT * FROM global_temp.people").show();

    // Un view global temporar este vizibil intre sesiuni
    sparkSession.newSession().sql("SELECT * FROM
global_temp.people").show();

    // Crearea seturilor de date (Dataset)
    val person0 = Person() // instanta de clasa Bean
    person0.name = "Mihai"
    person0.age = 20
    val person1 = Person() // instanta de clasa Bean
    person1.name = "Ana"
    person1.age = 19

    // Este creat un codificator (Encoder) pentru bean-ul Java
```

```
    val personEncoder: Encoder<Person> =
Encoders.bean(Person::class.java)
    // Se creeaza Dataset-ul de persoane
    val javaBeanDS: Dataset<Person> =
sparkSession.createDataset(listOf(person0, person1), personEncoder)
    javaBeanDS.show()

    // Codificatoarele (Encoders) pentru tipurile primitive sunt
furnizate de clasa Encoders
    val integerEncoder = Encoders.INT()
    val primitiveDS: Dataset<Int> =
sparkSession.createDataset(listOf(1, 2, 3), integerEncoder)
    val transformedDS = primitiveDS.map(
        MapFunction { value: Int -> value + 1 } as MapFunction<Int,
Int>,
        integerEncoder
    )
    transformedDS.collect() // [2, 3, 4]
    transformedDS.show() // afisarea listei transformate

    // DataFrame-urile pot fi convertite intr-un Dataset
    val path = "src/main/resources/people.json"
    val peopleDS: Dataset<Person> =
sparkSession.read().json(path).`as`(personEncoder)
    peopleDS.show()

    // Interoperabilitatea cu RDD-uri
    // Crearea unui RDD de obiecte Person dintr-un fisier text
    val peopleRDD: JavaRDD<Person> = sparkSession.read()
        .textFile("src/main/resources/people.txt")
        .javaRDD()
        .map { line ->
            val parts: List<String> = line.split(",")
            val person = Person()
            person.name = parts[0]
            person.age = parts[1].trim { it <= ' ' }.toInt()
            person // return
        }
    // Aplicarea unei scheme pe un RDD de Java Bean-uri pentru a
obtine DataFrame
    val peopleDF: Dataset<Row> =
sparkSession.createDataFrame(peopleRDD, Person::class.java)
    // Inregistrarea DataFrame-ului ca un view temporar
    peopleDF.createOrReplaceTempView("people")

    // Selectarea persoanelor intre 13 si 19 ani cu o interogare SQL
    val teenagersDF: Dataset<Row> = sparkSession.sql("SELECT name FROM
people WHERE age BETWEEN 13 AND 19")

    // Coloanele dintr-un Row din rezultat pot fi accesate dupa
indexul coloanei
    val stringEncoder = Encoders.STRING()
    val teenagerNamesByIndexDF = teenagersDF.map(
```

```
        MapFunction { row: Row -> "Name: " + row.getString(0) } as
MapFunction<Row, String>,
        stringEncoder
    )
    teenagerNamesByIndexDF.show()

    // sau dupa numele coloanei
    val teenagerNamesByFieldDF = teenagersDF.map(
        MapFunction { row: Row -> "Name: " + row.getAs("name") } ,
        stringEncoder
    )
    teenagerNamesByFieldDF.show()
}
```

Conţinutul fişierelor:

- src/main/resources/people.json

```
{"name":"Ionel"}
{"name":"Maria", "age":23}
{"name":"Vasile", "age":18}
{"name":"Ana", "age":23}
```

- src/main/resources/people.txt

```
Ionel, 17
Maria, 23
Vasile, 18
Ana, 23
```

Exemplul 3: Integrarea Spark Streaming cu Kafka

```
package com.sd.laborator

import org.apache.kafka.clients.consumer.ConsumerRecord
import org.apache.kafka.common.serialization.StringDeserializer
import org.apache.spark.SparkConf
import org.apache.spark.TaskContext
import org.apache.spark.api.java.JavaRDD
import org.apache.spark.api.java.JavaSparkContext
import org.apache.spark.streaming.Durations
import org.apache.spark.streaming.api.java.JavaInputDStream
import org.apache.spark.streaming.api.java.JavaStreamingContext
import org.apache.spark.streaming.kafka010.*
import scala.Tuple2


fun main() {
    // configurarea Kafka
    val kafkaParams = mutableMapOf<String, Any>(
        "bootstrap.servers" to "localhost:9092",
        "key.deserializer" to StringDeserializer::class.java,
        "value.deserializer" to StringDeserializer::class.java,
```

```
        "group.id" to "use_a_separate_group_id_for_each_stream",
        "auto.offset.reset" to "latest",
        "enable.auto.commit" to false
    )

    // configurarea Spark
    val sparkConf =
SparkConf().setMaster("local[4]").setAppName("KafkaIntegration")
    // initializarea contextului Spark
    val sparkContext = JavaSparkContext(sparkConf)
    // initializarea contextului de streaming
    val streamingContext = JavaStreamingContext(sparkConf,
Durations.seconds(1))


    val topics = listOf("topicA", "topicB")

    // crearea unui flux de date direct (DirectStream)
    val stream: JavaInputDStream<ConsumerRecord<String, String>> =
KafkaUtils.createDirectStream(
        streamingContext,
        LocationStrategies.PreferConsistent(),
        ConsumerStrategies.Subscribe(topics, kafkaParams)
    )
    stream.mapToPair{record: ConsumerRecord<String, String> ->
Tuple2(record.key(), record.value()) }

    // crearea unui RDD (set de date imutabil distribuit)
    val offsetRanges =
        arrayOf( /* topicul, partitia, offset-ul de inceput, offset-ul
final */
            OffsetRange.create("test", 0, 0, 100),
            OffsetRange.create("test", 1, 0, 100)
        )
    val rdd: JavaRDD<ConsumerRecord<String, String>> =
KafkaUtils.createRDD(
        sparkContext,
        kafkaParams,
        offsetRanges,
        LocationStrategies.PreferConsistent()
    )

    // obtinerea offset-urilor
    stream.foreachRDD { rdd ->
        val offsetRanges = (rdd.rdd() as
HasOffsetRanges).offsetRanges()
        rdd.foreachPartition { consumerRecords ->
            val o = offsetRanges.get(TaskContext.get().partitionId())
            println(
                o.topic() + " " + o.partition() + " " + o.fromOffset()
+ " " + o.untilOffset()
            )
        }
```

```
    }

    // stocarea offset-urilor
    stream.foreachRDD { rdd ->
      val offsetRanges = (rdd.rdd() as HasOffsetRanges).offsetRanges()
      (stream.inputDStream() as
CanCommitOffsets).commitAsync(offsetRanges)
    }

    streamingContext.start()
    streamingContext.awaitTerminationOrTimeout(1000)
}
```

Aplicaţii şi teme

Aplicaţii de laborator:

1. Consultând documentaţia oficială, reluaţi exemplul 1 şi configuraţi Spark să fie executat local pe câte core-uri sunt disponibile şi cu un număr de maxim 6 încercări de execuţie a unui task (RDD).

2. Să se calculeze cu ajutorul Spark RDD, Spark SQL şi Spark Streaming (deci 3 aplicaţii diferite) histograma caracterelor din alfabetul latin ([a-zA-Z]) dintr-un fişier text de tip ebook.
   Observaţie: când se utilizează Spark Streaming, fişierele text trebuie create în timp real (în timpul execuţiei aplicaţiei).

3. Să se implementeze un **Kafka Producer** în python care să citească un fişier text, să extragă cuvintele şi să le publice într-un topic. Să se creeze un direct stream folosind Spark Streaming şi din histograma cuvintelor, să se returneze cele mai frevente 15 cuvinte.
   Observaţie: **nu uita să porneşti server-ul Kafka** (vezi laboratorul 10).

Teme pe acasă:

1. Utilizând Spark Streaming și comanda NetCat[1] (nc), să se creeze un flux de date pe o conexiune TCP, care să preia input-ul text dintr-un terminal și să îl prelucreze astfel încât să elimine orice caracter care nu este literă și să aplice două transformări peste rezultatul obținut: prima va transforma toate literele de pe poziții impare în litere mari, iar a doua va insera după fiecare literă mare, numărul de apariții ale acesteia în string-ul respectiv.
2. Să se implementeze un Kafka Producer în python care să preia coordonatele mouse-ului timp de 10 secunde şi să le publice într-un topic (mouse-ul va trebui „plimbat” pe diagonala ecranului). Pornind de la exemplul 3, să se preia fluxul de puncte utilizând Spark Streaming şi să se realizeze o regresie liniară, calculând *covarianţa*.

   Pentru preluarea coordonatelor mouse-ului în Python, se poate utiliza scriptul de mai jos:

```
from pynput.mouse import Controller
import time

mouse = Controller()

if __name__ == "__main__":
    for _ in range(100):
        print(mouse.position)
```

[1] https://www.commandlinux.com/man-page/man1/nc.1.html

```
        time.sleep(0.1)
```

Trebuie instalată dependenţa *pynput:*

```
python3 -m venv env
source env/bin/activate
pip3 install pynput==1.6.8
```